

▼ Лабораторная работа №3

Обработка пропусков в данных, кодирование категориальных признаков, масштабирование данных

Выбрать набор данных (датасет), содержащий категориальные признаки и пропуски в данных. Для выполнения следующих пунктов можно использовать несколько различных наборов данных (один для обработки пропусков, другой для категориальных признаков и т.д.) Для выбранного датасета (датасетов) на основе материалов лекции решить следующие задачи: обработку пропусков в данных; кодирование категориальных признаков; масштабирование данных.

В чем состоит проблема: Если в данных есть пропуски, то большинство алгоритмов машинного обучения не будут с ними работать. Даже корреляционная матрица не будет строиться корректно. Большинство алгоритмов машинного обучения требуют явного перекодирования категориальных признаков в числовые. Даже если алгоритм не требует этого явно, такое перекодирование возможно стоит попробовать, чтобы повысить качество модели. Большинство алгоритмов показывает лучшее качество на отмасштабированных признаках, в особенности алгоритмы, использующие методы градиентного спуска.

► Загружаем окружение

↳ 12 cells hidden

▼ Работа с данными

```
1 | companies = pd.read_csv('acquisitions.csv', sep=',')
2 | companies.head(10)
```

⇨

```
AcquisitionID AcquisitionMonth AcquisitionMonthDate AcquisitionYear
```

0	ACQ99	November	11.0	2015
---	-------	----------	------	------

```
1 companies.shape
```

```
↪ (916, 10)
```

```
1 companies.dtypes
```

```
↪ AcquisitionID          object
    AcquisitionMonth       object
    AcquisitionMonthDate   float64
    AcquisitionYear        int64
    Company                object
    Business               object
    Country                object
    Value (USD)            float64
    Derived products        object
    ParentCompany           object
    dtype: object
```

7	ACQ99	January	10.0	2016
---	-------	---------	------	------

Проверка на пустые значения:

```
1 companies.isnull().sum()
2 # for column in companies.columns:
3 #     buf_null = companies[companies[column].isnull()].shape[0]
4 #     print ('{}-{}'.format(column, buf_null))
5
6 # acquisition - приобретение, овладение
7 # derived products - производные продукты
```

```
↪ AcquisitionID          0
    AcquisitionMonth       6
    AcquisitionMonthDate   33
    AcquisitionYear        0
    Company                0
    Business               0
    Country                46
    Value (USD)            671
    Derived products        515
    ParentCompany           0
    dtype: int64
```

Вывод: по полям AcquisitionMont, AcquisitionMonthDate, Country-46 - пропуски данных небольшие, это не сильно повлияет на анализ

- По полям Value (USD) и Derived products пропуски более 50% от dataset, сильное влияние

```
1 total_count = companies.shape[0]
2 print('Всего строк: {}'.format(total_count))
```

```
↪ Всего строк: 916
```

▼ 1. Обработка пропусков в данных

1.1. Простые стратегии - удаление или заполнение нулями Удаление колонок, содержащих пустые значения

```
1 data_new_1 = companies.dropna(axis=1, how='any')
2 (companies.shape, data_new_1.shape)
```

```
↪ ((916, 10), (916, 5))
```

```
1 data_new_1.head(.5).
```

	AcquisitionID	AcquisitionYear	Company	Business	ParentCompany
0	ACQ99	2015	bebop	Cloud software	Google
1	ACQ98	2015	Fly Labs	Video editing	Google
2	ACQ97	2015	Clearleap	Cloud-based video management	IBM
3	ACQ96	2015	Metanautix	Big Data Analytics	Microsoft
4	ACQ95	2015	Talko Inc	Mobile	Microsoft

```
1 data_new_1.shape
```

```
↪ (916, 5)
```

Удаление строк, содержащих пустые значения

```
1 data_new_2 = companies.dropna(axis=0, how='any')
2 (companies.shape, data_new_2.shape)
```

```
↪ ((916, 10), (114, 10))
```

```
1 data_new_2.head(.5).
```

	AcquisitionID	AcquisitionMonth	AcquisitionMonthDate	AcquisitionYear	C
0	ACQ99	November		11.0	2015
38	ACQ889	February		7.0	1997
47	ACQ880	October		8.0	1997

```
1 data_new_2.shape
```

⇨ (114, 10)

Заполнение всех пропущенных значений нулями

- В данном случае это некорректно, так как нулями заполняются в том числе категориальные колонки

```
1 data_new_3 = companies.fillna(0)
2 data_new_3.isnull().sum()
```

```
⇨ AcquisitionID          0
    AcquisitionMonth        0
    AcquisitionMonthDate    0
    AcquisitionYear          0
    Company                  0
    Business                 0
    Country                  0
    Value (USD)              0
    Derived products          0
    ParentCompany             0
dtype: int64
```

▼ 1.2. "Внедрение значений" - импьютация (imputation)

1.2.1. Обработка пропусков в числовых данных

- Импьютация - процесс замены пропущенных, некорректных или несостоительных значений другими значениями
- Выберем числовые колонки с пропущенными значениями
- Цикл по колонкам датасета
- Выберем числовые колонки с пропущенными значениями
- Цикл по колонкам датасета

```
1 num_cols = []
2 for col in companies.columns:
3     # Количество пустых значений
4     temp_null_count = companies[companies[col].isnull()].shape[0]
5     dt = str(companies[col].dtype)
6     total_count = companies.shape[0]
7     if temp_null_count > 0 and (dt == 'float64' or dt == 'int64'):
8         num_cols.append(col)
9     temp_perc = round((temp_null_count / total_count) * 100.0, 2)
10    print('Колонка {}. Тип данных {}. Количество пустых значений {}, {}%.'.format
```

⇨ Колонка AcquisitionMonthDate. Тип данных float64. Количество пустых значений 33, 3%. Колонка Value (USD). Тип данных float64. Количество пустых значений 671, 73.25%.

Фильтр по колонкам с пропущенными значениями

```
1 data_num = companies[num_cols]
2 data_num
```

⇨

	Acquisition Month	Date	Value (USD)
0		11.0	3.800000e+08
1		11.0	NaN
2		8.0	NaN
3		18.0	NaN
4		21.0	NaN
5		7.0	NaN
6		15.0	NaN
7		19.0	NaN
8		30.0	1.400000e+07
9		2.0	NaN
10		7.0	NaN
11		27.0	NaN
12		11.0	NaN
13		3.0	NaN
14		21.0	NaN
15		31.0	NaN
16		29.0	NaN
17		28.0	NaN
18		27.0	NaN
19		1.0	NaN
20		15.0	NaN
21		23.0	NaN
22		10.0	NaN
23		17.0	NaN
24		6.0	NaN
25		28.0	NaN
26		16.0	NaN
27		12.0	NaN
28		16.0	1.330000e+08
29		6.0	NaN
...
886		23.0	NaN
887		31.0	1.600000e+08

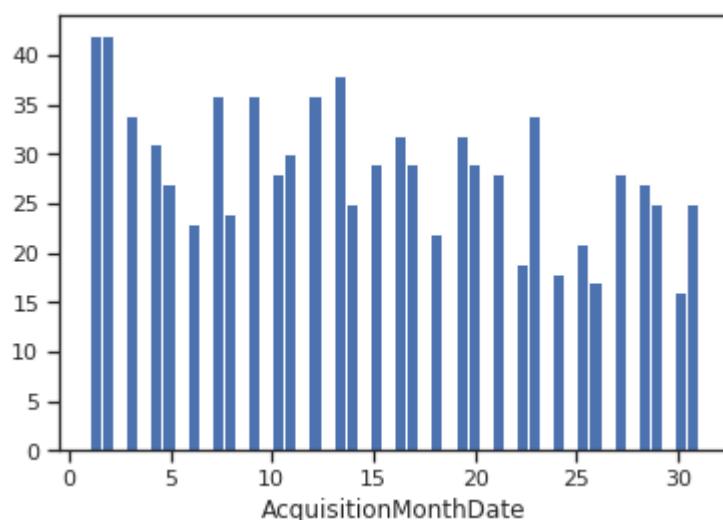
```
887          31.0    1.000000e+00
888          3.0      NaN
889          6.0    1.000000e+09
890          NaN      NaN
891          5.0      NaN
892          NaN      NaN
893          NaN      NaN
894          3.0      NaN
895          10.0     NaN
896          11.0     NaN
897          21.0     NaN
898          28.0     NaN
899          28.0     NaN
900          30.0     NaN
901          2.0      NaN
902          9.0      NaN
903          3.0      NaN
904          17.0     NaN
905          21.0     NaN
906          21.0     NaN
907          28.0     NaN
908          NaN      NaN
909          3.0      NaN
910          5.0      NaN
911          6.0    1.309000e+09
912          9.0      NaN
913          11.0     NaN
...          ...      ...
```

Гистограмма по признакам

```
1 | for col in data_num:
2 |     plt.hist(companies[col], 50)
3 |     plt.xlabel(col)
4 |     plt.show()
```



```
/usr/local/lib/python3.6/dist-packages/numpy/lib/histograms.py:824: RuntimeWarning: invalid value encountered in less than or equal to
  keep = (tmp_a >= first_edge)
/usr/local/lib/python3.6/dist-packages/numpy/lib/histograms.py:825: RuntimeWarning: invalid value encountered in less than or equal to
  keep &= (tmp_a <= last_edge)
```



Фильтр по пустым значениям поля AcquisitionMonthDate

```
1 | companies[companies['AcquisitionMonthDate'].isnull()]
```



162	ACQ777	October	NaN	2003
166	ACQ773	January	NaN	2004
182	ACQ759	September	NaN	2004
184	ACQ757	October	NaN	2004
198	ACQ744	March	NaN	2005
205	ACQ738	April	NaN	2005
218	ACQ726	July	NaN	2005
233	ACQ712	November	NaN	2005
301	ACQ651	December	NaN	2006
474	ACQ496	August	NaN	2010
571	ACQ408	NaN	NaN	2012
629	ACQ356	NaN	NaN	2013
630	ACQ355	NaN	NaN	2013
641	ACQ345	March	NaN	2013
713	ACQ280	December	NaN	2013
733	ACQ262	NaN	NaN	2014
840	ACQ166	January	NaN	2015
858	ACQ15	October	NaN	2017
862	ACQ146	April	NaN	2015

Запоминаем индексы строк с пустыми значениями

```
1 | flt_index = companies[companies['AcquisitionMonthDate'].isnull()].index
2 | flt_index
[→] Int64Index([ 45,  61,  99, 100, 144, 149, 150, 161, 162, 166, 182, 184, 198,
    205, 218, 233, 301, 474, 571, 629, 630, 641, 713, 733, 840, 858,
    862, 869, 872, 890, 892, 893, 908],
   dtype='int64')
```

Проверяем что выводятся нужные строки

```
1 | companies[companies.index.isin(flt_index)]
```

```
[→]
```

162	ACQ777	October	NaN	2003
166	ACQ773	January	NaN	2004
182	ACQ759	September	NaN	2004
184	ACQ757	October	NaN	2004
198	ACQ744	March	NaN	2005
205	ACQ738	April	NaN	2005
218	ACQ726	July	NaN	2005
233	ACQ712	November	NaN	2005
301	ACQ651	December	NaN	2006
474	ACQ496	August	NaN	2010
571	ACQ408	NaN	NaN	2012

фильтр по колонке

```
1 | data_num[data_num.index.isin(flt_index)][ 'AcquisitionMonthDate' ]
```



```
45      NaN
61      NaN
99      NaN
100     NaN
144     NaN
149     NaN
150     NaN
161     NaN
162     NaN
166     NaN
182     NaN
184     NaN
198     NaN
205     NaN
```

Будем использовать встроенные средства импьютации библиотеки scikit-learn - <https://scikit-learn.org/stable/modules/impute.html#impute>

```
1 data_num_AcquisitionMonthDate = data_num[ [ 'AcquisitionMonthDate' ] ]
2 data_num_AcquisitionMonthDate.head()
```

→ AcquisitionMonthDate

	AcquisitionMonthDate
0	11.0
1	11.0
2	8.0
3	18.0
4	21.0

500 NaN

```
1 from sklearn.impute import SimpleImputer
2 from sklearn.impute import MissingIndicator
```

Фильтр для проверки заполнения пустых значений

```
1 indicator = MissingIndicator()
2 mask_missing_values_only = indicator.fit_transform(data_num_AcquisitionMonthDat
3 mask_missing_values_only
```

→

